


# Generative Modeling (from Unsupervised Learning)

- Take as input training samples from some distribution and learn a model that represents that distribution  
PDF  
(cf. latent variable model: 관측가능한 변수세트를 잠재변수세트와 관련시키는 통계모델)

## → AutoEncoder




$$\begin{cases} h = f(W_h x + b_h) \\ \hat{x} = g(W_x h + b_x) \end{cases} \quad \begin{array}{l} \text{Reconstruction loss} \\ \ell(x, \hat{x}) = \frac{1}{2} \|x - \hat{x}\|^2 \end{array}$$

## Under / Over-complete Hidden Layer h

- (입력층의 차원) < (은닉층의 차원): Complete hidden layer 최적화 용이
- (입력층의 차원) > (은닉층의 차원): Under-Complete hidden layer 정규압축 용이

## 노이즈제거 Denoising AutoEncoder




복원능력 강화시 용이하다. input에 noise

$$x \xrightarrow{\text{잡음가함}} \tilde{x} \text{ (AutoEncoder)} \rightarrow \hat{x} \quad \begin{array}{l} \text{원본} \\ \text{과 가까워지도록} \end{array}$$

input에 noise

## 수축성 Contractive AutoEncoder



Loss 자체에 noise

$$\ell(x, \hat{x}) = \underbrace{\ell_{\text{reconstruction}}}_{\text{penalise insensitivity to reconstruction direction}} + \underbrace{\lambda \|\nabla_x h\|^2}_{\text{penalise sensitivity to the any direction.}}$$

• Variational Auto Encoder 변이형인코더

Sampler:  $(E(z), V(z))$  의 분포에서

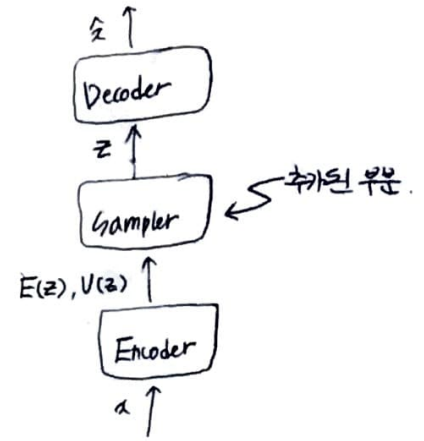
$z$ 를 샘플로 추출한다. 즉,  $E(z), V(z)$ 는

잠재변수  $z$ 를 생성하는 sampler

$$z = E(z) + \epsilon \odot \sqrt{V(z)} \quad (\epsilon \sim N(0, I_d))$$

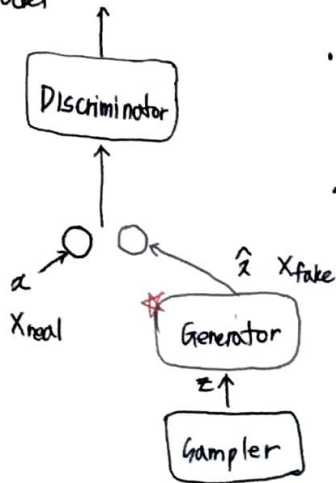
$$\text{Loss: } l(a, \hat{a}) = l_{\text{reconstruction}} + \underbrace{B\ell_{KL}(z, N(0, I_d))}_{\text{변칙항}}$$

즉, VAE는 AEA와 다르게 생성프로세스를 가능하게 하는 높은 잠재공간을 가지고 있다.



→ Generative Adversarial Networks (GANs) sample from something simple (noise), learn a transformation to the training distribution

### \* Basic Model



• Sampler: Sample to generate new instances (noise)

• Discriminator:  $x_{real}(x)$  와  $x_{fake}(\hat{x})$  를 구별

• Generator 블록에는 믿고자 하는 것.  
noise  $z \rightarrow x_{fake}(\hat{x})$

Problem) 1. 불안정한 수렴: 발생기(Generator) 성능↑ 이면 Discriminator 성능↓  
평형장치 피드백은 시간이 흐를수록 의미가 없어진다.


2. 경사사멸: D의 이진 크로스엔트로피 손실

$$L = E_x [\log(D(x))] + E_{\hat{x}} [\log(1 - D(\hat{x}))]$$

각각  $D(x) \rightarrow 1$ ,  $D(\hat{x}) \rightarrow 0$  으로 경사가 포화상태에 이르러 G의 학습을 방해.

3. 모드붕괴: 가짜와 진짜의 데이터가 순환해 공간 최소값에 갇히게 된다.

### \* Cycle GAN



### \* DCGAN

: original GAN에 CNN을 적용